

# エグゼクティブサマリー

## 研究テーマ

グラフニューラルネットワークを用いてサッカーのカウンターアタックの成功・失敗を予測する。特にモデル・予測の解釈性（説明可能性）を重視し、大きく以下の3つのアプローチで解釈性を向上させることを目指した。

- 1)モデルに経験的な制約や物理的な制約を加える
- 2)順列特徴重要度を用いてどの特徴量が重要視されていたのかを調べ、可視化する
- 3)GNNExpianerという手法を用いて特定の局面でどの選手間の相互作用が根拠となったかを可視化する

## 成果

- ・ベースラインが特定の指標に依存する傾向があったのに対して、本手法は戦術を理解しようとしている兆候が見られた
- ・全体としてはx速度（縦方向速度）とゴールへの距離が重要との一般則に対し、成功シーンや失敗シーンでは状況の違いにより特徴の重要度の優先順位を変更していることを確認できた
- ・7試合分のデータという制約の中で戦術的・物理的整合性を確保できた

## 技術スタック

Python、Pytorch

## 備考

本PDFにより成果物として添付した論文のご説明をさせていただきます。便宜上、論文で実行した2つの手法（経験的制約・物理的制約）のうち経験的制約の方のみを本PDFでは説明させていただきます。（補足資料として末尾に物理的制約の方の手法の解説も添付しております。）

# 「GNNを用いた対戦型スポーツにおける動的相互作用構造の抽出」

早稲田大学先進理工学応用物理学科4年 磯田龍哉

# 目次

1. 先行研究
2. 目的
3. 理論
4. 提案手法
5. 本研究における解釈性の定義
6. 結果・考察
7. 結論
8. 参考文献
9. 補足


# 1. 先行研究

## GNNを用いたサッカーのカウンターアタックの成功予測

論文名：「A Graph Neural Network deep-dive into successful counterattacks」 [1]


### 概要

- ・ サッカーをグラフ構造と捉え、グラフニューラルネットワークを用いて予測
- ・ 男女別、男女共通でそれぞれ実行



### 結論

- ・ 男女別のGNNが男女共通のモデルの性能を上回る
- ・ 大きな影響を与える特徴：PFI（順列特徴重要度）により、縦方向の速度、ゴールへの角度、ボールへの角度、横方向の速度



### 課題

深層学習モデルのブラックボックス性  
→ モデル・予測の**説明可能性（解釈性）**


## 2.本研究の目的

グラフニューラルネットワーク（GNN）に対し、  
戦術的知見に基づく「ヒューリスティックな誘導」を導入し、  
解釈性とデータサイズの制約へのアプローチを試みる

# 3.1 理論：GNN


## グラフニューラルネットワーク（GNN）とは

→ 深層学習をグラフ構造に応用した手法




### 問題点

グラフ構造のデータをどのようにニューラルネットワークに入力できる形にするか



### メッセージパッシング

自分自身の特徴  $h_i$  と隣接ノードの特徴  $h_j$ 、エッジの重み  $e_{ij}$  からメッセージ  $m_{ij}$  を作り、集約[3]  
→ 自分の状態を更新



## 3.2 理論：アテンション係数

### アテンション機構

近傍ノードから情報を集約する際の重み(アテンション係数 $\alpha_{ij}$ )を動的に決定する機構[2]

メッセージの生成：
$$\mathbf{m}_{ij}^{(l)} = \alpha_{ij} \mathbf{W}^{(l)} \mathbf{h}_j^{(l)}$$

動的に決定

メッセージの集約：
$$\mathbf{M}_i^{(l)} = \sum_{j \in \mathcal{N}(i) \cup \{i\}} \mathbf{m}_{ij}^{(l)}$$


「モデルがどのエッジを重要視しているか」を表す

$h_i$ :自分自身の状態  
 $h_j$ :隣接ノードの状態  
 $W$ :重み行列  
 $\sigma$ :シグモイド関数

状態の更新：

$$\mathbf{h}_i^{(l+1)} = \sigma \left( \mathbf{M}_i^{(l)} \right)$$

# 4.提案手法



1.予測位置を計算

$$\hat{\mathbf{p}}_i = \mathbf{p}_i + \mathbf{v}_i \cdot \tau$$

2. 2選手間の予測位置の差から**物理バイアス**を計算

$$B_{ij}^{\text{phys}} = \exp\left(-\frac{\|\hat{\mathbf{p}}_i - \hat{\mathbf{p}}_j\|_2}{\sigma}\right)$$

3.チームバイアスを導入

$$B_{ij}^{\text{team}} = \begin{cases} 0.5 & \text{if } T_i = T_j \\ -0.5 & \text{if } T_i \neq T_j \end{cases}$$


4.アテンションを計算 通常モデル

$$e_{ij} = \text{LeakyReLU}\left(\mathbf{a}^\top [\mathbf{W}\mathbf{x}_i \parallel \mathbf{W}\mathbf{x}_j] + B_{ij}^{\text{phys}} + B_{ij}^{\text{team}}\right)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$



# 4.提案手法



以下の損失関数を導入

$$Phys\_L = \text{ReLU} \left( -\frac{1}{N_{atk}} \sum_{i \in \text{Attackers}} v_{xi} \cdot \hat{y} \right)$$

# 5.本研究における解釈性の定義

3 階層からなる解釈性の定義を提案

- ・ **モデルの傾向 (Global)**

モデルがどの特徴量を重視するか



順列特徴重要度(PFI)

- ・ **内部の妥当性 (Internal)**

モデルの計算プロセスが、論理的・物理的に整合しているか



モデルの  
構造

- ・ **予測の根拠 (Local)**

特定の局面でどの選手間の相互作用が根拠となったか



GNNExplainer



# 6.1 結果・考察：順列特徴重要度

## 順列特徴重要度

予測全体でモデルがどの特徴量を重要視していたか

### 【算出方法】

ある特徴量をランダムに入れ替えて性能がどれだけ落ちるかを計算  
→すべての特徴量で実行




その特徴量を入れ替えて性能が落ちた特徴量ほど  
予測において重要だった

# 6.1 結果・考察：順列特徴重要度

## 順列特徴重要度(PFI)

普通のモデル（グラフ構造なし）

・MLPベースライン（灰色）の方が提案手法よりサッカーの戦術ではなく  
ゴールへ近いかやx方向速度が速いか  
などの相関に依存




# 6.3 結果・考察 : GNNExplainer

## GNNExplainerとは

予測に不可欠だった特徴量と部分グラフを抽出する手法[4]



### 【算出方法】

「どの部分グラフとどの特徴量を残せば元の予測結果を再現できるか？」を計算する（最適化計算）



その予測に不可欠だった**特徴の重要度**と**部分グラフ**がわかる


順列特徴重要度(PFI)との違い  
順列特徴重要度・・・予測タスク全体としての  
GNNExplainer・・・あるシーンにおける



# 6.3 結果・考察 : GNNExplainer (成功シーン)

## 成功シーン


### 特徴の重要度



・ カウンターの成功にはゴールへの素早い攻撃が重要との経験的知見、先行研究の結果と整合

## 部分グラフ


AI Prediction: SUCCESS  
(GT: Success)




・ 周辺守備選手への強いエッジ

# 6.4 結果・考察：成功シーンと全体の比較

## GNNExplainerと順列特徴重要度の比較



- ・全体としては x 速度とゴールへの距離が重要との一般則
- ・情報の優先順位を速度から位置の優位性へ切り替え




# 6.5 結果・考察 : GNNExplainer (失敗シーン)

失敗シーン

特徴の重要度


Feature Importance: AI Prediction: FAILURE



- ・ 目標領域から遠い位置にいることを失敗の決定的要因としている  
→ 経験的知見と整合

部分グラフ

AI Prediction: FAILURE  
(GT: Failure)





# 7. 結論

1. モデル・予測の解釈性を考察するために、  
順列特徴重要度（PFI）とGNNExplainerという 2 つの指標を用いた
  - ・ ベースラインが特定の指標に依存する傾向  
→ 本手法は戦術を理解しようとしている兆候
  - ・ 全体としては x 速度とゴールへの距離が重要との一般則に対し、  
成功シーンや失敗シーンでは状況の違いにより特徴の重要度の優先順位を変更
2. 7 試合分のデータという制約の中で戦術的・物理的整合性を確保できた

# 8.参考文献

- 1) Joris Bekkers<sup>1,2,3</sup> and Amod Sahasrabudhe, A Graph Neural Network deep-dive into successful counterattacks, U.S. Soccer Federation ,PySport ,UnravelSports, <https://arxiv.org/pdf/2411.17450>,October 2023
- 2) Petar Velićković, Guillem Cucurull, Arantxa Casanova, Adriana Romero, Pietro Liò, and Yoshua Bengio. Graph attention networks. In International Conference on Learning Representations (ICLR), 2018
- 3) Justin Gilmer, Samuel S Schoenholz, Patrick F Riley, Oriol Vinyals, and George E Dahl. Neural message passing for quantum chemistry. In International conference on machine learning, pages 1263–1272. PMLR, 2017.
- 4) Rex Ying, Dylan Bourgeois, Jiaxuan You, Marinka Zitnik, and Jure Leskovec. Gnnexplainer: Generating explanations for graph neural networks. In Advances in Neural Information Processing Systems (NeurIPS), volume 32, pages 9240– 9251, 2019
- 5) Manuel Bassek, Robert Rein, Hendrik Weber, and Daniel Memmert. An integrated dataset of spatiotemporal and event data in elite soccer. Scientific Data, 2025.

# 9.補足：実験設定（詳細）

## 使用データ

Scientific Dataで公開されている7試合分のトラッキングデータおよびイベントデータ[5]

## カウンター定義

TacklingGame（タックルによる奪取）、BallClaiming（ルーズボールの回収）、BallDeflection（パスインターセプト等によるこぼれ球の回収）の3種類のボール奪取イベントが発生した瞬間を起点とし、奪取した瞬間から1秒間（25フレーム）を抽出

## カウンターの成功の定義:

ボール奪取から5秒後に

- 垂直方向の推進力...ボール奪取から5秒以内に、ボールの反転後x座標が25mライン（敵陣深く）に到達している
- 攻撃の進展...自陣でのパス回しを排除するため、奪取地点から5秒後の地点までに、相手ゴール方向へ5m以上の実質的な前進を伴っている

## 9.補足： 結果・考察 評価指標

### 評価指標

物理損失の重み $\alpha_p$ ごとに実行

| モデル                | Precision   | Recall      | F1-score    |
|--------------------|-------------|-------------|-------------|
| MLP Baseline       | <b>0.31</b> | <b>0.64</b> | <b>0.42</b> |
| $\alpha_p = 0$     | <b>0.14</b> | <b>0.80</b> | <b>0.25</b> |
| $\alpha_p = 100.0$ | <b>0.20</b> | <b>0.73</b> | <b>0.31</b> |
| $\alpha_p = 200.0$ | <b>0.19</b> | <b>0.73</b> | <b>0.20</b> |

- ・ 提案モデルの中では100.0が最も良い
- ・ 提案手法はMLPベースラインよりも少ないカウンターの成功を検知する能力に優れる

# 9.補足：もう一つの提案手法

## 提案手法：Physics-Informedなモデル

モデルに物理法則を組み込み、物理的にありえない動きを排除する

①物理的検閲・・・「物理的にありえない移動はノイズとみる」

1人の選手に対して将来位置を計算

$$\mathbf{v}_j(t-1) = \frac{\mathbf{p}_j(t-1) - \mathbf{p}_j(t-2)}{\Delta t}$$

→実際の位置との差を計算

$$\hat{\mathbf{p}}_j(t) = \mathbf{p}_j(t-1) + \mathbf{v}_j(t-1) \cdot \Delta t$$

$$R_j = \|\mathbf{p}_j(t) - \hat{\mathbf{p}}_j(t)\|_2$$

→この差が大きいノードのメッセージパッシングを抑制

( $G_j$ は $R_j$ が閾値以下であれば1.0に、閾値を大きく超えれば0に漸近する)

$$G_j = \frac{1}{1 + \exp(-k(\theta - R_j))}$$

→アテンションを計算

$$e_{ij} = \text{LeakyReLU}(\mathbf{a}^\top [\mathbf{W}\mathbf{h}_i \parallel \mathbf{W}\mathbf{h}_j]) + \log(G_j + \epsilon)$$

$$\alpha_{ij} = \frac{\exp(e_{ij})}{\sum_{k \in \mathcal{N}(i)} \exp(e_{ik})}$$

②損失関数はそのまま